**总 token 消耗**

输入 + 输出 + 缓存读；成本口径与中转计费一致

